

Stream Processing Pipelines

MBA⁺

Plataforma Apache Spark

Prof. Rafael Pereira

- Stream Processing.
- Apache Spark.
- Apache Flink.
- Amazon Kinesis.
- Azure Stream Analytics.
- Google Cloud Dataflow .
- Event-Based vs. Micro-Batching.
- CI/CD: Continuous Integration / Continuous Delivery.

Stream Processing Solutions

- Stream Architecture
- Stream Processing vs. Batch Processing
- Características
- Componentes
- Ferramentas
- Aplicações
- Desafios

Plataforma Apache Spark

- Características
- Componentes
- Arquitetura
- Funcionamento
- Casos de Uso

Quem sou eu?

FIAP



- BACHAREL EM SISTEMAS DE INFORMAÇÃO - IMPACTA TECNOLOGIA
- LICENCIADO EM MATEMÁTICA - UNIVERSIDADE CRUZEIRO DO SUL
- PÓS-GRADUAÇÃO EM TECNOLOGIA EM SOFTWARE - USP
- PÓS-GRADUAÇÃO EM DIVERSIDADE E GÊNERO - UNIVERSIDADE DE SANTOS
- PÓS-GRADUAÇÃO EM GESTÃO DE PROJETOS - FECAP
- MESTRANDO EM CIÊNCIA DA COMPUTAÇÃO - UNIVERSIDADE DO CAMPO LIMPO



17 ANOS DE EXPERIÊNCIA EM TECNOLOGIA (IA, SOFTWARE E GESTÃO)

- MAKRO
- SODEXO
- BAYER
- CARREFOUR
- ITAÚ



makro



10 ANOS COMO DOCENTE

- FIAP
- SENAC
- CENTRO PAULA SOUZA
- FAMESP - MBA EM DATA SCIENCE



Por que Spark?

FIAP

O Dilema dos Dados Modernos


Executivos lidam com volumes massivos de dados, mas Excel e SQL Server são limitados.

Onde o Spark Entra

Apache Spark processa **terabytes de dados rapidamente**, integrando-se a análises executivas.

Quando Usar (e Quando Evitar)

- Use Spark para grandes volumes, streaming e machine learning.
- Evite para relatórios simples ou pequenos datasets.




Spark vs Ferramentas Tradicionais

FIAP

The screenshot shows a Microsoft Excel spreadsheet titled "Balance Sheet" for the year ending December 31, 2010. The table is divided into Assets and Liabilities sections, with sub-sections for Current and Long-term assets/liabilities. All values are in thousands of dollars.

Balance Sheet			
For Year Ending December 31, 2010			
(all numbers in \$000)			
ASSETS		LIABILITIES	
Current Assets:		Current Liabilities:	
Cash	\$51	Accounts payable	\$237
Accounts receivable (less doubtful accounts)	340	Short-term notes	23
(129)		Current portion of long-term notes	14
Inventory	175	Interest payable	5
Temporary investment	12	Taxes payable	10
Prepaid expenses	2	Accrued payroll	13
Total Current Assets	\$451	Total Current Liabilities	\$302
Fixed Assets:		Long-term Liabilities:	
Long-term investments	\$40	Mortgage	\$840
Land	650	Other long-term liabilities	425



Excel / SQL Server

- Ótimo para relatórios operacionais
- Fácil de aprender
- Limite de GBs de dados
- Lento com grandes volumes

Apache Spark

Escala para terabytes, processamento paralelo em memória, suporta batch/streaming, integra IA e analytics.

Casos de Uso no Brasil

FIAP




Nubank

Detecção de fraude em tempo real com Spark no Databricks usando streaming de transações.



iFood

Otimização de entregas com análise de tráfego e demanda em tempo real usando janelas temporais.



Magalu

Personalização de ofertas com processamento batch de milhões de pedidos diários.

Batch vs Streaming

FIAP



Processamento Batch: Relatório Mensal

Como um CFO que recebe um balanço fechado ao final do mês.

Processamento Streaming: Painel em Tempo Real

Como um COO monitorando vendas minuto a minuto durante uma Black Friday.

Ambos são essenciais – o primeiro para estratégia, o segundo para ação imediata.

Arquitetura Spark

FIAP



Driver

Como um CEO: coordena todas as tarefas e toma decisões centrais.

Executor


Como gerentes regionais: executam tarefas locais com autonomia.

Cluster

Como uma rede de lojas: escala conforme a demanda, integrando recursos.

Principais Benefícios do Databricks

FIAP



1 - Velocidade

Spark otimizado para nuvem: processamento acelerado.

2 - Colaboração

Notebooks compartilhados: equipes colaboram em tempo real.

3 - Escalabilidade

Infraestrutura elástica que cresce com a necessidade de dados.

4 - Segurança

Governança e conformidade regulatória: controles avançados.

O que é um Lakehouse?


Um Lakehouse une as vantagens de um data lake (baixo custo, escalabilidade) com as funcionalidades de um data warehouse (estrutura, qualidade, desempenho).

Como Funciona

Dados brutos entram, são organizados em camadas (bruta, enriquecida, analítica), permitindo consultas SQL rápidas e machine learning.


Impacto nos Negócios

Elimina a movimentação de dados entre sistemas, reduzindo complexidade e custos.



Fluxo de Trabalho no Databricks

FIAP



Ingestão

Coleta de dados de APIs, bancos e arquivos.

Transformação

Limpeza e estruturação com Spark SQL ou Python.

Modelagem

Criação de modelos

Visualização

Exportação para ferramentas de BI ou relatórios internos.

Por Que é Importante?

Em um mundo regulado (LGPD), a governança garante acesso ético e seguro aos dados.

Como o Databricks Ajuda 2

- Controle de acesso granular (usuário, grupo, função)
- Auditoria de acesso a dados 3
- Classificação automática de dados sensíveis

Aplicação Estratégica 4


Líderes tomam decisões confiantes, com dados confiáveis e em conformidade.



- Conceito: É um modelo de processamento de dados que realiza a transformação das informações em lotes menores (*micro-batching*) ou *on-demand*.
- Basicamente é o modelo oposto ao processo em batch tradicional, onde os dados são processados “de uma vez só” em lotes grandes de informações.
- Veremos nos próximos slides as diferenças arquiteturais e de implementação nas duas abordagens.

Stream Processing - Arquitetura

FIAP




Fonte: [Amazon](#)


Stream Processing vs. Batch Processing

FIAP

Batch Processing



Stream Processing



Fonte: [K21Academy](#)

Stream Processing vs. Batch Processing

FIAP

Característica	Batch	Stream
Natureza do Dado	Lotes Grandes	Lotes Pequenos / Fluxo
Latência	Elevada	Baixa
Escalabilidade	Vertical	Horizontal
Complexidade do Código	Baixa	Alta
Uso de Memória	Elevada	Baixa
Tolerância a Falhas	Implementação Simples	Implementação Complexa

- Dica: Lembre-se que a tabela possui comparativos de alto-nível e genéricos, o caso concreto pode mudar as características e a performance do processo!

- O processamento e análise de dados em tempo-real habilita cenários de negócio e de tecnologia na qual se precisa de um tempo de reação reduzido.
- Especialmente em empresas *data-driven* ou *event-driven*, ter um tempo de resposta menor se torna um diferencial de mercado.

- Ingestão de Dados: Coleta e pré-processamento dos dados, que podem vir de forma tanto estruturada como não-estruturada.
- Processamento em Tempo Real: Transformação, Agregação e Filtragem dos Dados.
- Saída de Resultados: Geração de Insights em Tempo Real para outras Aplicações ou Analistas.

- Apache Kafka: Plataforma de streaming distribuída para ingestão e transmissão de dados.
- Apache Flink: Motor de processamento de dados em streaming e em lote de alto desempenho.
- Apache Spark Streaming: Processamento de streaming no ecossistema Apache Spark.
- Dentre outras soluções em nuvem: Amazon Kinesis, Azure Stream Analytics, Google Cloud Dataflow, etc.

- Real-Time Social Media Monitoring.
- Network Traffic Analytics (Security).
- Credit Card Fraud Detection and Analysis.
- Server Monitoring (Observability).
- IoT Systems Monitoring.

- Escalabilidade: Gerenciar os picos de carga de dados.
- Gerenciamento de Estado: Manter o estado do sistema em tempo real.
- Tolerância a Falhas: Construir pipelines robustos à interrupções de rede e erros de processamento.
- Complexidade: Streams são bem mais complexos de se construir e manter.

- Não há ferramenta que cuida de todos os cenários de processamento de maneira performática.
- Comparativo Interessante entre Ferramentas:
<https://www.upsolver.com/blog/popular-stream-processing-frameworks-compared>

- Definição: O Apache Spark possui um motor de processamento de dados com capacidade de processar grandes volumes de dados de forma rápida e de fácil gerenciamento.
- Criado em 2013 e permite a codificação de pipelines de processamento em múltiplas linguagens de programação, mais notadamente Scala, Java, SQL, Python, R e C#.




- Velocidade: Processamento *in-memory* (mais detalhes a seguir) para cargas de trabalho em batch e/ou em streaming.
- Escalabilidade: Escala horizontalmente para lidar com volumes de dados massivos (Ideal para cenários de Cloud e Big Data).
- Ecossistema: Integração com Hadoop, MLlib, GraphX, etc.

- Apache Spark Core: Motor de execução.
- Spark SQL: Módulo de Processamento SQL.
- Spark Streaming: Módulo de Processamento em Tempo Real.
- MLlib: Biblioteca de Machine Learning.
- GraphX: Processamento de Gráficos.

Apache Spark - Arquitetura

FIAP



Fonte: [ResearchGate](#)

- Processamento em Memória: Minimiza o uso de I/O de disco, aproveitando a memória para maior velocidade e *throughput*.
- Resiliência: Tolerância a falhas por meio do uso do DAG (Directed Acyclic Graph) e recuperação de RDDs.
- API: Oferece suporte a várias linguagens e diversos formatos de data sources.

- Real-Time Data Analytics.
- Processamento de ETL com Carga Massiva de Dados.
- Machine Learning.
- Graph Analytics.
- Processamento de Logs e Eventos.

- Vamos conhecer um pouco do Apache Spark e suas funcionalidades principais.
- Criar uma carga de dados fake.
- Realizar a ingestão de dados.
- Visualização da carga de dados.

| Dúvidas?

FIAP



MBA⁺

Copyright © **2023-2025** - Prof. Rafael Tsuji Matsuyama
e Prof. Rafael S Novo Pereira

Todos direitos reservados. Reprodução ou divulgação
total ou parcial deste documento é expressamente
proibido sem o consentimento formal, por escrito, do
Professor (autor).